

# TRABAJO PRÁCTICO FINAL: TÉCNICAS DE PRODUCCIÓN DE CONOCIMIENTO ACADÉMICO Y PROFESIONAL (TPCAP)

Profesora: María Gabriela Ertola Navajas

Alumno: Martín Basualdo

Correo: martin.basualdo@hotmail.com

Grupo: 8

Universidad de San Andrés

Fecha: Septiembre, 2023



Universidad de  
**SanAndrés**

# Índice

<b>1. Introducción</b>	<b>2</b>
<b>2. Sobre el dataset</b>	<b>3</b>
2.1. Elección de variables exógenas . . . . .	3
2.2. Análisis descriptivo . . . . .	4
<b>3. Correlación entre las variables</b>	<b>6</b>
3.1. Spearman . . . . .	6
3.2. Regresión múltiple . . . . .	7
<b>4. Predicción</b>	<b>8</b>
4.1. Estimación MCO . . . . .	9
4.2. Estimación SARIMAX . . . . .	11
<b>5. Conclusión</b>	<b>13</b>
<b>6. Referencias</b>	<b>15</b>
<b>A. Anexo I: modelos para exógenas en la regresión múltiple</b>	<b>16</b>
<b>B. Anexo II: modelos para exógenas en el SARIMAX</b>	<b>21</b>

## 1. Introducción

El presente trabajo tiene como fin utilizar las herramientas cuantitativas vistas en el curso. En particular, busco establecer una relación entre las precipitaciones, la brecha cambiaria, el tipo de cambio a precios constantes, el índice de precios de los productos primarios con el valor de las exportaciones de los productos primarios. Para ello, primero realizo un análisis teórico de las relaciones entre las variables, justificando la elección de las variables exógenas y describiendo estadísticamente el *dataset*. Luego planteo una correlación entre las variables mediante la correlación de *Spearman* y una regresión múltiple robusta a la heterocedasticidad, señalando la importancia en los supuestos de los distintos métodos. En la tercera sección, presento una predicción de la variable central bajo análisis para los siguientes 6 meses mediante un modelo MCO robusto a la heterocedasticidad, y un modelo SARIMAX. En el primero, la metodología para seleccionar al mejor modelo fue el mayor AIC para los rezagos de cada variable. En el segundo, se utilizó la metodología de *cross-validation* aplicado para series de tiempo.

Las conclusiones esperadas en cuanto a los ejercicios de correlación no son los esperados inicialmente. La brecha cambiaria entre el tipo de cambio oficial y el contado con liquidación se encuentra positivamente correlacionado con el valor exportado de los productos primarios; el tipo de cambio oficial a precios constantes presentó una correlación negativa en relación a la variable de interés. Las precipitaciones, por su lado, se encuentran negativamente correlacionadas con el valor exportado de los productos primarios. Las posibles razones de estos resultados fueron desarrolladas en la misma sección 3.

Por su parte, el resultado final de predicción suena razonable dada la fuerte sequía que atravesó el país en el 2023. El modelo de MCO robusto a la heterocedasticidad estima una caída del 13,3% interanual para el mes de junio de 2023, mientras que el SARIMAX estima una caída del 12,5% interanual para ese mismo mes. En este sentido, existe espacio para mejora, dado que la caída fue subestimada y las bandas que reflejan el intervalo de confianza son amplias.

Para realizar el trabajo utilicé Python. Las librerías `plotly`, `matplotlib` y `seaborn` fueron especialmente útiles para la parte gráfica. Para la estadística, utilicé `pandas` para el análisis descriptivo, y `statsmodels` y `sklearn` para el cálculo y evaluación de los modelos. Para optimizar la calibración de los modelos, `multiprocessing` permitió acelerar el proceso de 22 horas a 12 horas. Para mantener actualizada la base de datos para futuros trabajos, el *web scraping* utilicé `selenium` y `alphacast`.

El código utilizado puede encontrarse en el siguiente [repositorio de GITHUB](#).

## 2. Sobre el dataset

La serie de tiempo del valor (en millones de USD) de las exportaciones de los productos primarios inicia en enero del 2005 y finaliza en diciembre del 2022. La frecuencia es mensual. Su inicio está dado por los datos disponibles, y su final, por ser el momento en que se produjo mi primer intento en hacer una estimación para los siguientes seis meses.

### 2.1. Elección de variables exógenas

Las exportaciones de los productos primarios (**pp**) pueden depender de:

1. Sus precios (**pi**): Un aumento en el precio del producto, dependiendo de la elasticidad precio de la oferta, debería generar un aumento en la cantidad exportada. El índice de precios de los productos primarios publicado por el INDEC es de ayuda en ese sentido. Sin embargo, hay que tener en cuenta que  $valor = precio * cantidad$ , por lo que esta variable exógena contiene, lógicamente, información de la endógena.
2. Las precipitaciones (**pre**): Una sequía debería generar una caída en el valor de las exportaciones de los productos primarios. No existe evidencia de que Argentina sea un país *pricemaker*, por lo que los precios no deberían verse afectados por una sequía que altere la producción nacional. Las precipitaciones tienen como fuente *alphacast* en base a NCEI, y son un promedio simple entre las estaciones meteorológicas de Rosario, Junín y Marcos Juárez; los valores se expresan en décimas de milímetro.
3. El tipo de cambio (**er\_cp**), entendido como el precio relativo para los bienes transables, debería, en teoría, incentivar a las firmas exportadoras de productos primarios al aumentar su poder adquisitivo en moneda local. Un aumento en el tipo de cambio fijaría, a priori, una suba en la rentabilidad en moneda doméstica si el *pass-through* no es total. Se trata del tipo de cambio deflactado por el índice de inflación (fuente: BCRA, INDEC y GERES).
4. La brecha entre el tipo de cambio oficial y el dólar contado con liquidación (**gap**) incide en las decisiones de los exportadores al ser un indicador de una expectativa de devaluación. Una mayor brecha incentiva una retención de los saldos exportables ante la incertidumbre cambiaria. Inicia en 1.0 al ser resultado del ratio entre el tipo de cambio oficial y el dólar contado con liquidación.

## 2.2. Análisis descriptivo


En el Cuadro 1 pueden verse las estadísticas descriptivas de cada una de las variables. Es interesante notar un valor atípico en la variable de las precipitaciones de -0,7 décimas de milímetro para el mes de mayo del 2008. El resto de las observaciones son típicas. En total, cuento con 216 observaciones.

Cuadro 1: Estadísticas descriptivas de las variables

	pp	pi	gap	er_cp	pre
count	216.0	216.0	216.0	216.0	216.0
mean	1286.5	158.6	1.3	511.7	830.3
std	497.8	33.0	0.3	147.0	663.3
min	363.8	86.2	1.0	347.1	-0.7
25 %	899.7	137.9	1.0	389.7	250.0
50 %	1205.8	151.4	1.1	472.2	711.0
75 %	1640.7	187.2	1.4	578.4	1236.4
max	2766.4	223.3	2.4	896.5	3448.0

Cuando observamos la serie histórica (Figura 1), se denota una dinámica particular para cada una de las variables. El valor de los productos primarios tiende a crecer en el tiempo, pero está marcado por una fuerte estacionalidad. El comportamiento de los precios de los productos primarios pareciera adquirir una forma más cíclica. La brecha entre el tipo de cambio oficial y el contado con liquidación comenzó a ser relevante con posterioridad al año 2012, se corrigió a mediados de diciembre del 2016, pero se reactivó en agosto del 2019. El tipo de cambio a precios constantes, por su parte, muestra una tendencia a la baja, con algunos saltos bruscos. Por último, las precipitaciones son prácticamente imposible de analizar dada la fuerte estacionalidad.

Figura 1: Evolución histórica de las variables bajo análisis




Para evitar el efecto de la estacionalidad, podríamos hacer la siguiente operación para obtener la serie anualizada (Figura 2):

- Suma acumulada del valor de las exportaciones de los productos primarios.
- Media del índice de precios de los productos primarios.<sup>1</sup>
- Media de la brecha y del tipo de cambio a precios constantes.
- Suma acumulada de las precipitaciones.

Ahora sí podemos observar la fuerte sequía del 2008 y lo que se avecina para el 2023. De todas maneras, pese a que es de público conocimiento, la sequía del 2018 no es perceptible. Esto puede ser reflejo de datos de mala calidad o de un indicador no correcto. Esta es una cuestión a mejorar.

<sup>1</sup> Esto no es lo correcto, ya que debería descargarse la serie anual, es algo a mejorar, pero sirve como aproximación.

Figura 2: Evolución histórica de las variables bajo análisis (Frecuencia anual)



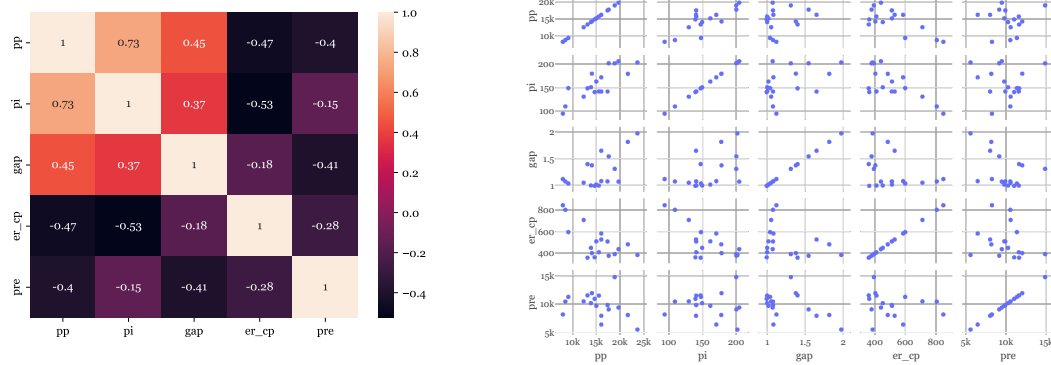
### 3. Correlación entre las variables

#### 3.1. Spearman

La presente sección muestra la correlación entre las variables seleccionadas. Como la correlación de *Pearson* supone una distribución normal y una relación lineal, opté por utilizar la correlación de *Spearman*, que los flexibiliza. El resultado puede observarse en la Figura 3. La correlación entre el índice de precio de las exportaciones de los productos primarios presenta una correlación de 0,73 con su valor. Esto es lógico dado que el valor es el resultado de la multiplicación del precio y la cantidad: a mayor precio, mayor será el valor. Lo sorprendente está con la dinámica del tipo de cambio y las precipitaciones. Existe una correlación positiva con la brecha cambiaria y negativa con el tipo de cambio a precios constantes. Es decir, a mayor brecha cambiaria, el valor exportado de los productos primarios aumenta, mientras que a menor tipo de cambio, mayor será **pp**. Esto puede ser producto de que el tipo de cambio

apreciado se produjo en épocas donde el precio de los productos primarios fueron altos (2013, 2020, 2021 y 2022); la muestra es pequeña. Y vale la pena la aclaración: correlación no implica causalidad. Las precipitaciones también muestran una correlación anti-intuitiva frente a **pp**, ya que es negativa: a mayor lluvia, menores son las exportaciones. Esto podría explicarse por el número reducido de observaciones, un fuerte efecto del “ciclo de los *commodities*”, una probable mala calidad de la información, y debido a que importan las precipitaciones en los períodos en que la producción se encuentra en crecimiento.

Figura 3: Correlación de Spearman - Scatter



### 3.2. Regresión múltiple

Por otro lado, puede realizarse una regresión múltiple para encontrar si dichas correlaciones son estadísticamente significativas. Cuando regreso **pp** contra **pre**, las precipitaciones no tienen un efecto significativo sobre los productos primarios. La constante indica que si no llueve en todo el año, se exportan 21.372 millones de dólares “por defecto”.

A medida que incorporamos las demás variables exógenas, la significatividad va variando. En su expresión más completa, las precipitaciones presentan una significatividad a un nivel de confianza del 90 %. Su coeficiente indica que una décima de milímetro más de lluvia reduce las exportaciones en 538 mil dólares. El índice de precios es estadísticamente significativo a un nivel de confianza del 95 %, y su coeficiente predice que un aumento de 1 punto se correlaciona con un aumento de 64,2 millones de dólares en las exportaciones de los productos primarios. La brecha cambiaria no es significativa estadísticamente. El tipo de cambio a precios constantes es significativo estadísticamente a un nivel de confianza del 90 %, cuyo coeficiente informa que una devaluación de un peso por dólar (a pesos de diciembre del



Cuadro 2

	<i>Dependent variable: pp</i>			
	(1)	(2)	(3)	(4)
const	21371.676*** (6202.771)	3806.585 (3212.754)	497.787 (3874.682)	12503.487 (8527.205)
er_cp				-9.352* (4.698)
gap			2931.512* (1563.304)	2297.120 (1815.744)
pi		105.428*** (14.492)	92.696*** (13.159)	64.219** (22.484)
pre	-0.596 (0.609)	-0.510* (0.245)	-0.347 (0.205)	-0.538* (0.301)
Observations	18	18	18	18
$R^2$	0.090	0.716	0.743	0.789
Adjusted $R^2$	0.033	0.678	0.688	0.724
Residual Std. Error	4197.541 (df=16)	2421.729 (df=15)	2382.936 (df=14)	2244.923 (df=13)
F Statistic	0.957 (df=1; 16)	27.455*** (df=2; 15)	20.623*** (df=3; 14)	26.205*** (df=4; 13)

Note:

\*p&lt;0.1; \*\*p&lt;0.05; \*\*\*p&lt;0.01

2022) reduce en 9,35 millones de dólares las exportaciones de los productos primarios.

Los problemas con la regresión son evidentes:

- El número de observaciones es muy pequeño (18 años).
- Los supuestos de la regresión por mínimos cuadrados ordinarios no se cumplen. Por sobre todas las cosas, puede no existir una relación lineal (las precipitaciones pueden contribuir positivamente en niveles muy bajos, pero negativamente en niveles muy altos). La única corrección que se aplicó es que fue una regresión robusta a la heterocedasticidad, por lo que no se hace el supuesto de homocedasticidad.
- No incorpora los rezagos. Las decisiones de producción / liquidación no necesariamente se toman a partir de las observaciones en el momento ( $t$ ), sino que pueden ser consecuencia de las observaciones en el pasado ( $t-n$ ).
- La calidad de los datos sobre las precipitaciones está puesta en duda.

## 4. Predicción

La intención de la siguiente sección es la de predecir qué va a suceder en los próximos 6 meses en el valor de las exportaciones de los productos primarios. Para ello, planteo dos modelos: mínimos cuadrados ordinarios (robusto a la heterocedasticidad) y SARIMAX.

No se hará interpretación de los coeficientes ni de la significancia estadística dado que el único fin es el de poder predecir.

#### 4.1. Estimación MCO

Tanto las variables exógenas como la endógena no son series estacionarias según el test de Dickey Fuller (DF) aumentado. Esta es una fuente de sesgo a la hora de estimar una predicción. El problema se soluciona al implementar la diferenciación. De esta manera, en base al test de DF aumentado, las series se convierten en estacionarias.

Existe, lógicamente, una fuerte autocorrelación entre las variables, por lo que se incorporan los rezagos como variables exógenas. Pero, ¿cuántos rezagos debería utilizar? Siguiendo los lineamientos de Stock y Watson (pág. 392), el modelo con menor AIC debería ser el correcto. En consecuencia, se corrieron múltiples regresiones incorporando los rezagos de cada una de las variables para evaluar cuál presenta el menor criterio de información Akaike. Lógicamente, como se trata de una predicción a 6 meses, no es posible incorporar los rezagos de menor plazo. Los rezagos comienzan por el sexto. A modo de ejemplo, la elección de los rezagos óptimos de la variable `pre` se obtuvieron al seleccionar la regresión con menor AIC de:

$$\Delta pp_t = \beta_0 + \beta_1 \Delta pp_{t-6} + \beta_2 \Delta pp_{t-7} + \dots + \beta_6 \Delta pp_{t-12} \quad (1)$$

$$\Delta pp_t = \beta_0 + \beta_1 \Delta pp_{t-6} + \beta_2 \Delta pp_{t-7} + \dots + \beta_5 \Delta pp_{t-11} \quad (2)$$

La calibración del modelo (Anexo I) indica que para la variable endógena, se tienen que utilizar hasta 12 rezagos, para el índice de tipo de cambio real, hasta 6 rezagos, para el índice de precios hasta 6 rezagos, para las precipitaciones hasta 12 rezagos y para la brecha hasta 11 rezagos.

<b>Dep. Variable:</b>	pp	<b>R-squared:</b>	0.343
<b>Model:</b>	OLS	<b>Adj. R-squared:</b>	0.260
<b>Method:</b>	Least Squares	<b>F-statistic:</b>	5.549
<b>Date:</b>	Sat, 25 Nov 2023	<b>Prob (F-statistic):</b>	1.75e-11
<b>Time:</b>	22:49:03	<b>Log-Likelihood:</b>	-1345.7
<b>No. Observations:</b>	197	<b>AIC:</b>	2737.
<b>Df Residuals:</b>	174	<b>BIC:</b>	2813.
<b>Df Model:</b>	22		
<b>Covariance Type:</b>	HC1		

	coef	std err	t	P>  t	[0.025	0.975]
const	6.5676	17.037	0.385	0.700	-27.059	40.194
er_cp_lag_6	0.5459	1.193	0.458	0.648	-1.809	2.901
pi_lag_6	1.8655	2.240	0.833	0.406	-2.555	6.286
pre_lag_6	0.0560	0.027	2.062	0.041	0.002	0.110
pre_lag_7	0.0061	0.035	0.173	0.863	-0.063	0.075
pre_lag_8	-0.0070	0.040	-0.175	0.861	-0.086	0.072
pre_lag_9	-0.0057	0.042	-0.138	0.891	-0.088	0.076
pre_lag_10	-0.0181	0.038	-0.476	0.635	-0.093	0.057
pre_lag_11	-0.0480	0.035	-1.366	0.174	-0.117	0.021
pre_lag_12	-0.0200	0.030	-0.668	0.505	-0.079	0.039
pp_lag_6	-0.2009	0.075	-2.686	0.008	-0.349	-0.053
pp_lag_7	-0.1542	0.072	-2.148	0.033	-0.296	-0.013
pp_lag_8	-0.0236	0.069	-0.343	0.732	-0.160	0.112
pp_lag_9	0.1002	0.068	1.484	0.140	-0.033	0.234
pp_lag_10	0.0273	0.069	0.395	0.694	-0.109	0.164
pp_lag_11	0.0488	0.071	0.688	0.493	-0.091	0.189
pp_lag_12	0.2748	0.071	3.846	0.000	0.134	0.416
gap_lag_6	-278.6136	230.490	-1.209	0.228	-733.530	176.303
gap_lag_7	-223.8711	220.548	-1.015	0.311	-659.164	211.422
gap_lag_8	-227.6302	294.068	-0.774	0.440	-808.030	352.769
gap_lag_9	400.2308	314.993	1.271	0.206	-221.469	1021.930
gap_lag_10	-163.5031	411.295	-0.398	0.691	-975.272	648.266
gap_lag_11	316.7828	273.701	1.157	0.249	-223.418	856.983
<hr/>						
Omnibus:	6.045	Durbin-Watson:	2.298			
Prob(Omnibus):	0.049	Jarque-Bera (JB):	6.020			
Skew:	0.321	Prob(JB):	0.0493			
Kurtosis:	3.567	Cond. No.	2.21e+04			

Notes:

[1] Standard Errors are heteroscedasticity robust (HC1)

[2] The condition number is large, 2.21e+04. This might indicate that there are strong multicollinearity or other numerical problems.

En definitiva, el modelo quedaría especificado de la siguiente manera:


$$\begin{aligned}
\Delta pp_t = & \beta_0 + \beta_1 \Delta pp_{t-6} + \beta_2 \Delta pp_{t-7} + \dots + \beta_6 \Delta pp_{t-12} + \\
& \beta_7 \Delta er_{cp_{t-6}} + \beta_8 \Delta pi_{t-6} + \beta_9 \Delta pre_{t-6} + \dots + \beta_{15} \Delta pre_{t-12} + \\
& + \beta_{16} \Delta gap_{t-6} + \dots + \beta_{20} \Delta gap_{t-11}
\end{aligned} \tag{3}$$

Una vez obtenidos los parámetros, se obtiene la predicción de  $\Delta pp_t$ , al que debe aplicarse una reversión como para encontrar **pp-t**:  $pp_t = \Delta pp_t + pp_{t-1}$

La regresión logra predecir una caída en las exportaciones. De hecho, predice una caída

interanual del 13,3 % para el mes de junio 2023, y un valor de 1.764,9 millones de US\$. Sin embargo, cuando añado un nivel de confianza del 90 % para estimar los valores máximos y mínimos posibles (mejor y peor escenario), la brecha es punitivamente alta.

Figura 4: Predicción de las exportaciones de los siguientes 6 meses en base a una regresión múltiple.  
Nivel de confianza: 90 %



## 4.2. Estimación SARIMAX

El modelo SARIMAX tiene como ventaja que trata a los problemas de estacionalidad (al agregarle la **S** - “seasonal”- al inicio, incluyendo los componentes estacionales), a los de estacionariedad (al diferenciar en la medida en que la **i** -“integrated”- así lo indique), a los de correlación serial entre los errores y las variables exógenas (componentes **MA** y **AR**, respectivamente). La **X** de la especificación hace referencia a las variables exógenas de la regresión. En definitiva, el modelo se verá de la siguiente manera:


$$(p, d, q)(P, D, Q, M)$$

Donde **p** representa al orden **AR**, **d**, al orden **i**, **q**, al orden **MA**. (**P**,**D**,**Q**) representan a los órdenes **ARIMA** pero con respecto a los valores de **M** períodos pasados.

Para llevar a cabo el modelo, tuve que elegir los parámetros óptimos. Lo único que tomé como dado es que  $M = 12$  para las series con estacionalidad, como la de los productos primarios (ver Figura 5).

La elección de los parámetros óptimos se basó en la metodología de *crossvalidation*, ya que permite predicciones más robustas en series de tiempo (Bergemeir & Benítez, 2012). Dicha metodología propone separar la base de datos en 5 *sets*. Es decir, se divide en 5 partes iguales para aplicarle el siguiente procedimiento:

Figura 5




1. Primero toma el 20 % como datos y estima los siguientes 20 % de los datos. Se obtiene el error cuadrático medio sobre dicha predicción.
2. Luego toma el 40 % de los datos iniciales para estimar los siguientes 20 % de los datos. Se obtiene el error cuadrático medio sobre dicha predicción.
3. Luego toma el 60 % de los datos iniciales para estimar los siguientes 20 % de los datos. Se obtiene el error cuadrático medio sobre dicha predicción.
4. Luego toma el 80 % de los datos iniciales para estimar los siguientes 20 % de los datos. Se obtiene el error cuadrático medio sobre dicha predicción.
5. Una vez obtenidos dichos errores cuadráticos medios sobre las predicciones en cada una de las divisiones, se calcula una media simple de dicha métrica.

Por lo tanto, de esta manera utilizo toda la información disponible para asegurarme que los parámetros de mi modelo permiten generalizar correctamente sobre los datos. El objetivo particular es evitar que se entrene “ demasiado bien” sobre los datos brindados, pero sin capacidad alguna de predecir al futuro.

Para hacer una estimación a futuro, sin embargo, debo contar con los datos de las demás variables para el período que deseo estimar. Opté por estimar un modelo que ayude a predecir cada una de ellas bajo la misma metodología. El máximo de los parámetros  $p$  y  $q$  fue de 9, y de  $i$  fue de 1, y  $P, D, Q$ , fue de 9. De esta manera, se entrenaron 6.400 modelos por variable. Los resultados para cada una de las variables pueden verse en el Anexo II.

El resultado final puede observarse en la Figura 6, donde la predicción para junio del 2023 fue de 1.780,2 millones de dólares, es decir, una caída del 12,5 % interanual. Las cotas superiores e inferiores no se encuentran tan separadas como con la regresión múltiple. El peor escenario da un valor de 1.126 millones de dólares, mientras que el mejor, 2.434. Sigue siendo alta la diferencia entre las cotas.

Figura 6



## 5. Conclusión

En el presente trabajo se buscó establecer una relación entre las precipitaciones, la brecha cambiaria, el tipo de cambio a precios constantes, el índice de precios de los productos primarios con el valor de las exportaciones de los productos primarios. Para ello, primero se analizó el dataset, justificando las relaciones causales de las variables exógenas sobre la endógena y describiendo sus principales estadísticas. Allí se encontró un espacio para mejorar el modelo, ya que las precipitaciones no reflejan la fuerte sequía del 2018. Esto puede deberse a mala calidad de la información, o que simplemente el indicador no sea el correcto. También pudo encontrarse que posee datos negativos en un mes (*outlier*).

Luego se analizó la correlación entre las variables. Las conclusiones no son las esperadas: las precipitaciones se correlacionan negativamente con el valor de las exportaciones de los productos primarios al igual que el tipo de cambio a precios constantes; la brecha cambiaria entre el tipo de cambio oficial y el contado con liquidación presentó una relación positiva. En ese sentido, la regresión múltiple sostuvo la relación negativa tanto para las precipitaciones como para el tipo de cambio a precios constantes en relación a la variable endógena.

En la sección 4, se presenta una predicción del valor de las exportaciones de los productos primarios para los 6 siguientes meses mediante dos modelos: MCO y SARIMAX. El modelo de MCO robusto a la heterocedasticidad se calibró mediante el criterio de información AIC, mientras que los parámetros del modelo SARIMAX se obtuvieron a partir de la metodología *cross-validation*. Los resultados son los esperados: se estima una caída en los productos primarios para el año 2023, donde son conocidos los estragos de la sequía y de un tipo de cambio atrasado. Sin embargo, existe un gran espacio para mejora, dado que las cotas superiores e inferiores a un nivel de confianza del 90 % presentan una diferencia significativa. Al mismo tiempo, la estimación de la caída subestima a lo que efectivamente sucedió.

## 6. Referencias

- Butkiewicz, J.L., & Yanıkkaya, H. (2006). *Institutional quality and economic growth: Maintenance of the rule of law or democratic institutions, or both?* *Economic Modelling*, 23, 648-661.
- Bergmeir, C., Hyndman, R. J., & Koo, B. (2018). A note on the validity of cross-validation for evaluating autoregressive time series prediction. *Computational Statistics & Data Analysis*, 120, 70-83. <https://doi.org/10.1016/j.csda.2017.11.003>
- Cieřlik, A., & Goczek, L. (2018). *Control of corruption, international investment, and economic growth – Evidence from panel data.* *World Development*, 103, 323-335.
- Chandra, A. (2010). *Does Government Expenditure on Education Promote Economic Growth? An Econometric Analysis.* *Journal of Practicing Managers*.
- Levine, R. (1999). *Law, Finance, and Economic Growth.* *Journal of Financial Intermediation*, 8, 8-35.
- Nawaz, S. (2015). *Growth effects of institutions: A disaggregated analysis.* *Economic Modelling*, 45, 118-126.
- Park, J. (2012). *Corruption, soundness of the banking sector, and economic growth: A cross-country study.* *Journal of International Money and Finance*, 31, 907-929.
- Solow, R. M. (1956). *A contribution to the theory of economic growth.* *The quarterly journal of economics*, 70(1), 65-94.
- Suwandaru, A., Alghamdi, T., & Nurwanto, N. (2021). *Empirical Analysis on Public Expenditure for Education and Economic Growth: Evidence from Indonesia.* *Economies*, 9(4), 146. MDPI AG. Retrieved from <http://dx.doi.org/10.3390/economies9040146>



## A. Anexo I: modelos para exógenas en la regresión múltiple

Los rezagos de las variables exógenas se seleccionaron a partir de la métrica AIC.

	<i>Dependent variable: pp</i>						
	(1)	(2)	(3)	(4)	(5)	(6)	(7)
const	5.417 (18.732)	6.920 (18.103)	7.536 (18.053)	7.078 (18.035)	7.011 (18.163)	6.591 (18.168)	3.986 (17.672)
pp_lag_10					0.012 (0.067)	0.007 (0.067)	0.015 (0.065)
pp_lag_11						0.053 (0.072)	0.050 (0.066)
pp_lag_12							0.262*** (0.074)
pp_lag_6	-0.352*** (0.065)	-0.328*** (0.062)	-0.329*** (0.062)	-0.328*** (0.063)	-0.327*** (0.062)	-0.316*** (0.064)	-0.220*** (0.070)
pp_lag_7		-0.252*** (0.067)	-0.242*** (0.068)	-0.241*** (0.069)	-0.241*** (0.069)	-0.239*** (0.069)	-0.192*** (0.065)
pp_lag_8			-0.108* (0.061)	-0.117* (0.062)	-0.117* (0.063)	-0.115* (0.062)	-0.107* (0.060)
pp_lag_9				0.088 (0.061)	0.087 (0.061)	0.087 (0.060)	0.095 (0.059)
Observations	203	203	203	203	203	203	203
$R^2$	0.116	0.176	0.187	0.194	0.194	0.196	0.249
Adjusted $R^2$	0.112	0.168	0.174	0.177	0.173	0.172	0.222

Note:

\*p<0.1; \*\*p<0.05; \*\*\*p<0.01  
Model 1 AIC: 2846.9504413904124  
Model 2 AIC: 2834.8533411236417  
Model 3 AIC: 2834.152934547933  
Model 4 AIC: 2834.363449348367  
Model 5 AIC: 2836.3316841935116  
Model 6 AIC: 2837.710622143547  
Model 7 AIC: 2825.9703584036497

	<i>Dependent variable: er_cp</i>						
	(1)	(2)	(3)	(4)	(5)	(6)	(7)
const	-2.108*	-2.043*	-1.855	-2.073*	-2.181**	-1.758	-1.795
	(1.078)	(1.079)	(1.141)	(1.095)	(1.098)	(1.152)	(1.152)
er_cp_lag_10					-0.065	-0.132	-0.135
					(0.091)	(0.110)	(0.110)
er_cp_lag_11						0.240*	0.247*
						(0.140)	(0.149)
er_cp_lag_12							-0.022
							(0.085)
er_cp_lag_6	0.061	0.051	0.061	0.076	0.073	0.081	0.083
	(0.052)	(0.052)	(0.054)	(0.058)	(0.061)	(0.062)	(0.062)
er_cp_lag_7		0.038	0.011	-0.005	0.003	0.015	0.013
		(0.056)	(0.055)	(0.062)	(0.059)	(0.041)	(0.042)
er_cp_lag_8			0.100	0.137*	0.128*	0.097	0.096
			(0.068)	(0.078)	(0.074)	(0.071)	(0.070)
er_cp_lag_9				-0.132	-0.114	-0.083	-0.080
				(0.084)	(0.076)	(0.073)	(0.071)
Observations	203	203	203	203	203	203	203
$R^2$	0.004	0.005	0.014	0.030	0.034	0.087	0.088
Adjusted $R^2$	-0.001	-0.005	-0.000	0.011	0.010	0.060	0.055

*Note:*

\*p<0.1; \*\*p<0.05; \*\*\*p<0.01  
Model 1 AIC: 1686.4168966915558  
Model 2 AIC: 1688.136143652318  
Model 3 AIC: 1688.2210757017574  
Model 4 AIC: 1686.8820298355522  
Model 5 AIC: 1688.0716191366166  
Model 6 AIC: 1678.585497549554  
Model 7 AIC: 1680.486868456265

	<i>Dependent variable: gap</i>						
	(1)	(2)	(3)	(4)	(5)	(6)	(7)
const	0.004 (0.005)	0.004 (0.005)	0.004 (0.005)	0.004 (0.005)	0.004 (0.005)	0.004 (0.005)	0.003 (0.005)
gap_lag_10					-0.029 (0.088)	-0.025 (0.090)	-0.001 (0.090)
gap_lag_11						-0.021 (0.093)	-0.047 (0.095)
gap_lag_12							0.140 (0.102)
gap_lag_6	-0.019 (0.111)	-0.005 (0.115)	0.024 (0.121)	0.024 (0.121)	0.023 (0.121)	0.022 (0.120)	0.030 (0.121)
gap_lag_7		-0.078 (0.108)	-0.112 (0.121)	-0.104 (0.121)	-0.103 (0.122)	-0.103 (0.122)	-0.101 (0.118)
gap_lag_8			0.168 (0.132)	0.159 (0.133)	0.154 (0.136)	0.155 (0.137)	0.159 (0.136)
gap_lag_9				0.045 (0.108)	0.050 (0.107)	0.047 (0.113)	0.042 (0.113)
Observations	203	203	203	203	203	203	203
$R^2$	0.000	0.005	0.025	0.026	0.027	0.027	0.041
Adjusted $R^2$	-0.005	-0.005	0.010	0.007	0.002	-0.003	0.006

*Note:*

\*p<0.1; \*\*p<0.05; \*\*\*p<0.01  
Model 1 AIC: -461.9366391555511  
Model 2 AIC: -460.8454223034287  
Model 3 AIC: -463.00051461539533  
Model 4 AIC: -461.29394680140035  
Model 5 AIC: -459.4150708252346  
Model 6 AIC: -457.4795933425992  
Model 7 AIC: -458.28749735268593

	<i>Dependent variable: pi</i>						
	(1)	(2)	(3)	(4)	(5)	(6)	(7)
const	0.547 (0.550)	0.530 (0.559)	0.506 (0.574)	0.527 (0.580)	0.585 (0.573)	0.598 (0.563)	0.521 (0.559)
pi_lag_10					-0.105 (0.065)	-0.105 (0.065)	-0.117* (0.068)
pi_lag_11						-0.022 (0.079)	-0.022 (0.079)
pi_lag_12							0.131 (0.101)
pi_lag_6	-0.085 (0.073)	-0.085 (0.073)	-0.089 (0.075)	-0.089 (0.075)	-0.105 (0.078)	-0.106 (0.079)	-0.101 (0.076)
pi_lag_7		0.032 (0.071)	0.031 (0.071)	0.035 (0.073)	0.036 (0.071)	0.032 (0.068)	0.040 (0.069)
pi_lag_8			0.046 (0.084)	0.047 (0.084)	0.057 (0.085)	0.057 (0.085)	0.076 (0.084)
pi_lag_9				-0.044 (0.069)	-0.043 (0.069)	-0.040 (0.071)	-0.042 (0.071)
Observations	203	203	203	203	203	203	203
$R^2$	0.008	0.009	0.011	0.013	0.024	0.025	0.042
Adjusted $R^2$	0.003	-0.001	-0.004	-0.007	-0.000	-0.005	0.008

*Note:*

\*p<0.1; \*\*p<0.05; \*\*\*p<0.01  
Model 1 AIC: 1419.8129801777802  
Model 2 AIC: 1421.592632676808  
Model 3 AIC: 1423.1376039469505  
Model 4 AIC: 1424.7202764574522  
Model 5 AIC: 1424.3604453524458  
Model 6 AIC: 1426.2613863235179  
Model 7 AIC: 1424.6081755050561

	<i>Dependent variable: pre</i>						
	(1)	(2)	(3)	(4)	(5)	(6)	(7)
const	-6.687 (53.818)	-6.778 (53.856)	-6.679 (53.949)	-6.505 (54.095)	-6.627 (54.143)	-6.513 (54.149)	-5.587 (53.869)
pre_lag_10					-0.061 (0.073)	-0.030 (0.082)	-0.001 (0.082)
pre_lag_11						0.063 (0.080)	0.137 (0.084)
pre_lag_12							0.144** (0.070)
pre_lag_6	-0.101 (0.074)	-0.128 (0.083)	-0.134 (0.083)	-0.135 (0.083)	-0.141* (0.084)	-0.133 (0.084)	-0.102 (0.083)
pre_lag_7		-0.065 (0.084)	-0.086 (0.088)	-0.091 (0.088)	-0.096 (0.088)	-0.086 (0.087)	-0.052 (0.086)
pre_lag_8			-0.046 (0.074)	-0.064 (0.078)	-0.074 (0.076)	-0.068 (0.076)	-0.040 (0.075)
pre_lag_9				-0.037 (0.077)	-0.066 (0.081)	-0.055 (0.084)	-0.040 (0.084)
Observations	203	203	203	203	203	203	203
$R^2$	0.010	0.014	0.016	0.017	0.020	0.023	0.039
Adjusted $R^2$	0.005	0.004	0.001	-0.003	-0.005	-0.007	0.005

*Note:*

\*p<0.1; \*\*p<0.05; \*\*\*p<0.01  
Model 1 AIC: 3274.6844733018424  
Model 2 AIC: 3275.963872345592  
Model 3 AIC: 3277.604330501704  
Model 4 AIC: 3279.3678410580164  
Model 5 AIC: 3280.7336824247773  
Model 6 AIC: 3282.0628368647276  
Model 7 AIC: 3280.696841952911

## B. Anexo II: modelos para exógenas en el SARIMAX

El modelo “óptimo” se seleccionó en base al criterio *crossvalidation*. Para las precipitaciones existían predicciones negativas, por lo que se aplicó logaritmo a los datos y se le sumó 1 para evitar  $\log(0)$ , luego se invirtió exponenciando la predicción. Los resultados se ven en la Figura 6.

Figura 7

